FinNews Tracker

Phân tích cảm xúc tin tức tài chính Việt Nam theo từng công ty niêm yết
Tài liệu kế hoạch triển khai cho nhóm 5 người · cập nhật ngày 03/11/2026 (bản trước: 26/10/2026)

Thay đổi so với bản 26/10/2026:

- Thêm mục 2.7 **Dữ liệu cần crawl và tiến độ crawl**: crawler vietstock bản 2 đã lấy được nội dung bài, đang chạy.
- Thêm **chạy tự động hằng ngày** trọn luồng: crawl → làm sạch → gắn công ty → chấm sentiment → DB → web.
- Web app thêm **bộ lọc nguồn tin** (cạnh mã và khoảng ngày) và **bảng xếp hạng mã theo tin tức** trên trang chủ.
- Gộp tin trùng giữa các báo (cột `dup_group_id`), thêm bảng `ticker_rankings` vào schema.
- Cập nhật tình trạng gắn công ty và lọc equity news; lịch 8 tuần ghi theo ngày (bắt đầu 15/10/2026).

1. Ý tưởng của project

Xây dựng một hệ thống theo dõi cảm xúc (sentiment) của tin tức về các công ty niêm yết ở Việt Nam. Hệ thống tự thu thập bài báo từ các trang tin tài chính như **vietstock.vn**, **diendandoanhnghiep.vn**, **baodautu.vn** (lấy lại dữ liệu lịch sử và cập nhật mỗi ngày). Mỗi bài được gắn với những công ty mà bài nhắc tới, sau đó mô hình phân loại bài đó là **tích cực / tiêu cực / trung lập đối với từng công ty**. Trên web app, nhà đầu tư chọn một công ty (hoặc mã chứng khoán), một khoảng thời gian và nguồn tin để xem có bao nhiêu bài tích cực, tiêu cực, kèm link tới từng bài; trang chủ xếp hạng các mã đang có tin tức tích cực nhất.

Điểm mới so với hướng cũ: trước đây mỗi bài chỉ có một nhãn sentiment chung (cấp bài báo). Ý tưởng mới yêu cầu nhãn theo từng cặp (bài báo, công ty). Ví dụ bài "VNM tăng trưởng mạnh, trong khi MSN báo lỗ" phải ra tích cực với VNM và tiêu cực với MSN, chứ không phải một nhãn chung cho cả bài.

Luồng xử lý của hệ thống



2. Những gì đã làm được

Quan trọng: bộ 126.576 bài (2010–2023) hiện có chỉ là **dữ liệu thử**, dùng để viết và kiểm tra code. Toàn bộ dữ liệu chính thức được crawl lại từ đầu từ 3 trang tin (mục 2.7). Thứ dùng lại được là code

> (làm sạch, gắn công ty, model), nhãn tay (sau khi ánh xạ sang bài mới) và kinh nghiệm rút ra từ bộ thử.

2.1 Bộ dữ liệu thử

- Bộ thử: **126.576 bài** tin về doanh nghiệp và cổ phiếu, 01/2010 → 12/2023 (`data_news/equity_news_clean_content.parquet`). Nguồn: vietstock.vn 111.883 · diendandoanhnghiep.vn 10.407 · baodautu.vn 2.083 · stockbiz.vn 1.568 · dantri.com.vn 635.
- Code làm sạch đã chạy được trên bộ thử: bỏ ký tự rác, chuẩn hoá ngày đăng và tên miền, bỏ đoạn quảng cáo / "Có thể bạn quan tâm", chỉ giữ ~20 chuyên mục liên quan doanh nghiệp (thư mục `EDA_clean/`).

2.2 Danh mục công ty, bộ gắn công ty và lọc equity news

- Danh sách **1.945 mã** chứng khoán (`vn_stock_symbols.csv`): tên chính thức, **395 tên cũ** trước khi đổi tên (tìm từ kho tin, kiểm tra trên web), tên thương hiệu, sàn, trạng thái niêm yết.
- Bộ gắn công ty theo luật (`call_firm_extractor.py`, `run_firm_extractor.py`): tìm mã CK và tên công ty trong tiêu đề, sapo, nội dung; xử lý mã dễ nhầm với từ thường, tên dùng chung nhiều mã, tên rút gọn, mã kèm tên sàn trong ngoặc. Kết quả trên bộ thử: **245.363 cặp bài–mã**, **108.157 bài** có ít nhất 1 mã (85%).
- Lọc equity news (`filter_equity_news.py`): phân loại bài (tin công ty, tin nhiều mã, tin thị trường, nhắc qua…), chọn công ty chính / phụ là chủ thể. **110.903 / 126.576 bài** là equity news. Trên 100 bài gán tay: **đúng 96%** (precision 0,99, recall 0,96), so với 79% nếu chỉ lọc theo chuyên mục.
- Sơ đồ chi tiết các luật: `Firm_extractor/firm_equity_pipeline.png`; tổng quan nghiên cứu liên quan: `Firm_extractor/tong_quan_tai_lieu.md`.

2.3 Gán nhãn thủ công

- **2.033 bài** đã gán nhãn tay (cấp bài báo): Trung lập 1.135 · Tiêu cực 519 · Tích cực 379. Chia sẵn 1.035 bài train/tune và 998 bài Holdout.
- Hai người gán độc lập: khớp nhau 75,2%, weighted kappa (quadratic) 0,63. Lớp Tích cực khớp thấp nhất (56%) → hướng dẫn gán nhãn mới cần định nghĩa rõ "tích cực".
- Trong 2.033 bài: 1.274 bài chỉ có 1 công ty (dùng lại nhãn ngay cho cặp bài–công ty), 534 bài có ≥ 2 công ty (phải gán lại theo từng công ty), 225 bài không tìm thấy công ty.
- Nhãn đang gắn với số thứ tự bài trong bộ thử (`source_row_id`); khi crawl lại cần ánh xạ sang bài mới theo tiêu đề + ngày đăng.

2.4 Mô hình sentiment (cấp bài báo, trên bộ thử)

- PhoBERT-base-v2 qua 3 bước: **E1** – đọc thêm 126 nghìn bài tin tài chính (perplexity 8,25 → 3,82); **E2** – giữ nguyên PhoBERT, chỉ train lớp phân loại (baseline); **E3** – fine-tune toàn bộ trên bộ nhãn tay.
- Đánh giá: cross-validation lặp lại, nhiều seed, kiểm tra một lần trên Holdout (`sentiment_label_method/improve/`).
- Chấm cả bộ thử: bài dài chia đoạn ≤ 256 token rồi gộp; `net_sentiment_score = P(tích cực) − P(tiêu cực)`.

2.5 Repo

- Đã sửa import / đường dẫn, thêm `README.md`, `requirements.txt`, đưa các bảng tra cứu nhỏ vào git (26/10/2026).
- Còn lại: dữ liệu và model lớn không nằm trong git → cần nơi lưu chung (VD Google Drive).

2.6 Bảng tình trạng (03/11/2026)

Hạng mục	Tình trạng	Còn thiếu
Dữ liệu chính thức	**Đang crawl**	vietstock đang lấy danh sách bài (mục 2.7); chưa tải nội dung; chưa có 2 trang còn lại.
Crawler	**Một phần**	vietstock bản 2 lấy được nội dung, chạy tiếp khi bị ngắt, chia nhiều máy; chưa có crawler diendandoanhnghiep, baodautu; chưa chạy tự động hằng ngày.
Làm sạch dữ liệu	**Một phần**	Script rời; cần gom thành pipeline cho dữ liệu mới; chưa có bước gộp tin trùng giữa các báo.
Gắn công ty + lọc equity news	**Đã có**	Chưa đo precision / recall của bộ gắn công ty trên ~300 bài; chưa trích câu ngữ cảnh cho model.
Nhãn cấp bài báo	**Đã có**	2.033 bài, phải ánh xạ sang bài crawl mới.
Nhãn theo từng công ty	**Chưa có**	Cần hướng dẫn gán nhãn và gán lại cho bài nhiều công ty.
Model sentiment theo công ty	**Chưa có**	Đúng lịch (tuần 4–5). Model cấp bài (E3) dùng làm baseline.
Database, API, Web app	**Có kế hoạch**	Kế hoạch chi tiết cho 2 người (`docs/gợi_ý_fe_be_db.pdf`); chưa có code.
Job tự động hằng ngày	**Chưa có**	Nối crawl → làm sạch → gắn công ty → chấm điểm → DB → xếp hạng.

2.7 Dữ liệu cần crawl và tiến độ crawl MỚI

Mục tiêu: toàn bộ tin doanh nghiệp / cổ phiếu của 3 trang, **từ 01/2010 đến nay**, có nội dung bài, sau đó tự cập nhật mỗi ngày.

Nguồn	Phạm vi lấy	Ước tính số bài	Đã crawl (03/11/2026)
vietstock.vn	12 kênh tin cổ phiếu / doanh nghiệp (Hoạt động kinh doanh, Giao dịch nội bộ, Cổ phiếu, Cổ tức, Tăng vốn - M&A, Niêm yết, IPO, ETF, Trái phiếu DN, Chính sách, Phân tích cơ bản, Chứng quyền), 01/2010 → nay	~250 nghìn (2010–2012 trung bình ~14,5 nghìn bài/năm × 17 năm; chốt lại khi lấy xong danh sách)	Danh sách bài: **48.857 bài**, 01/2010 → 06/2013, đang chạy. Nội dung: chưa tải.
diendandoanhnghiep.vn	Chuyên mục doanh nghiệp, sớm nhất có thể → nay	Chưa ước tính (bộ thử: 10.407 bài sau lọc chuyên mục)	Chưa có crawler
baodautu.vn	Chuyên mục doanh nghiệp / sức khoẻ doanh nghiệp, sớm nhất có thể → nay	Chưa ước tính (bộ thử: 2.083 bài)	Chưa có crawler

Crawler vietstock bản 2 (`Crawler/crawl_vietstock_ver2.py`) chạy 2 pha: **meta** lấy danh sách bài theo kênh × tháng (~1 request / 10 bài), **content** tải từng trang bài để lấy sapo, nội dung, từ khoá, tác giả; pha content chia được cho nhiều máy (`--shard K/N`).

3. Phân công cho 5 người

Chia theo các bước của luồng xử lý. Mỗi người sở hữu một phần và một đầu ra rõ ràng; các phần nối với nhau qua schema ở mục 4. Crawl lại toàn bộ dữ liệu là việc dài nhất, phải chạy liên tục; trong lúc chờ, TV3,

TV4, TV5 phát triển trên bộ thử.

Thành viên 1 — Thu thập dữ liệu (Crawler) · việc dài nhất

Phụ trách bước ① và phần crawl của job hằng ngày ⑦ · Tên: _____

Việc cần làm

- **Đã có:** crawler vietstock bản 2 lấy nội dung bài, chạy tiếp khi bị ngắt.
- Chạy xong pha meta và pha content của vietstock 2010 → nay (chia nhiều máy nếu chậm).
- Viết crawler diendandoanhnghiep.vn và baodautu.vn, cùng bộ cột với vietstock.
- Kiểm tra độ phủ: số bài theo tháng / kênh so với bộ thử, tìm tháng bị thiếu.
- Chế độ cập nhật hằng ngày: chỉ lấy bài mới, chống trùng theo link, log, tự thử lại khi lỗi.
- Crawl lịch sự: giới hạn tốc độ, User-Agent rõ ràng, tôn trọng robots.txt.

Đầu ra

- Thư mục `Crawler/` với 3 crawler cùng bộ cột.
- Dữ liệu raw đầy đủ 3 trang (parquet) đúng schema `raw_articles`.
- 1 lệnh lấy bài mới mỗi ngày, VD `python -m Crawler.daily`.
- Báo cáo độ phủ theo tháng / trang.

Phối hợp

- Giao raw cho TV2 theo từng đợt, không chờ xong hết.

Thành viên 2 — Pipeline dữ liệu, Database & job hằng ngày

Phụ trách bước ②, ⑤ và job tự động ⑦ · Tên: _____

Việc cần làm

- Gom các script trong `EDA_clean/` thành một pipeline làm sạch cho dữ liệu crawl mới (backfill và bài mới mỗi ngày).
- Gán `article_id` ổn định cho mỗi bài (theo link).
- **MỚI** Gộp tin trùng giữa các báo: cùng mã chủ thể, đăng cách nhau ≤ 48 giờ, tiêu đề + sapo giống nhau → cùng `dup_group_id`.
- Ánh xạ 2.033 nhãn cũ sang bài mới (khớp tiêu đề + ngày đăng), báo cáo số bài không khớp.
- Dựng database (PostgreSQL) theo schema mục 4; nạp dữ liệu mới.
- Job hằng ngày: crawl → làm sạch → gắn công ty → chấm sentiment → ghi DB → **MỚI** tính lại `ticker_rankings`; chạy theo lịch (cron / Task Scheduler).

Đầu ra

- Corpus sạch từ dữ liệu crawl mới, đã gộp tin trùng.
- Bảng ánh xạ nhãn cũ → `article_id` mới.
- DB đủ bảng ở mục 4.
- `pipeline/daily_job.py` chạy trọn luồng.

Phối hợp

- Nhận raw từ TV1; gọi hàm của TV3, TV4; cung cấp DB cho TV5.

Thành viên 3 — Gắn công ty vào bài (Entity Linking)

Phụ trách bước ③ · Tên: _____

Việc cần làm

- **Đã có:** tên cũ, thương hiệu, mã dễ nhầm, tên dùng chung; phân biệt công ty chủ thể / nhắc qua; lọc equity news.
- Lập tập đánh giá ~300 bài → đo precision / recall của bộ gắn công ty; gán thêm 100–200 bài ngẫu nhiên để đo lại bước lọc equity.
- Với mỗi cặp (bài, công ty): trích các câu có nhắc công ty làm ngữ cảnh cho model của TV4.
- Cập nhật danh sách mã (mới niêm yết, đổi tên, huỷ niêm yết); chạy lại trên dữ liệu crawl mới.

Đầu ra

- Hàm `link_companies(article)` → `[{symbol, mention_count, position, is_subject, context}]`.
- Báo cáo độ chính xác.

Phối hợp

- Cung cấp ngữ cảnh cho TV4; hàm được TV2 gọi trong pipeline.

Thành viên 4 — Model sentiment theo từng công ty

Phụ trách bước ④ · Tên: _____

Việc cần làm

- Viết hướng dẫn gán nhãn cho cặp (bài, công ty), định nghĩa rõ lớp Tích cực; điều phối cả nhóm gán nhãn (mục 5).
- Dựng bộ nhãn: tái dùng 1.274 bài một công ty; gán lại theo từng công ty cho 534 bài nhiều công ty; bổ sung bài mới cho cân bằng lớp.
- Baseline: nhãn E3 cấp bài gán cho mọi công ty chủ thể trong bài.
- Model chính: fine-tune PhoBERT (từ checkpoint E1/E3) với đầu vào có "đích", VD `[mã/tên công ty] </s> [các câu nhắc công ty]`.
- So sánh với baseline, nhất là trên bài nhiều công ty; báo cáo macro-F1 trên Holdout.
- Hàm suy luận cho bài mới mỗi ngày (job của TV2 gọi).

Đầu ra

- `entity_labels.csv` + hướng dẫn gán nhãn.
- Checkpoint + hàm `predict(article, company)` → `(label, score)`.
- Bảng so sánh baseline vs model mới.

Thành viên 5 — Backend API & Web app

Phụ trách bước ⑥ · Tên: _____ · chi tiết: `docs/gợi_ý_fe_be_db.pdf`

Việc cần làm

- API (FastAPI): tìm công ty theo mã/tên; đếm bài tích cực / tiêu cực / trung lập theo khoảng ngày **và nguồn**; danh sách bài kèm link, ngày, nguồn, nhãn; dữ liệu biểu đồ.
- MỚI Bộ lọc nguồn tin: Tất cả / vietstock / diendandoanhnghiep / baodautu. "Tất cả" đếm mỗi tin một lần (theo `dup_group_id`).
- MỚI Bảng "Top mã có tin tích cực" trên trang chủ: chọn 7 / 30 / 90 ngày và nguồn; hiện cả Top tiêu cực; click mã → trang công ty.
- Giao diện: ô tìm mã có gợi ý, chọn ngày và nguồn, thẻ tổng số bài theo nhãn, biểu đồ theo thời gian, bảng bài có link.
- Đóng gói Docker; chuẩn bị kịch bản demo.

Đầu ra

- Thư mục `app/` (backend + frontend).
- Web chạy bằng `docker compose up`.

Phối hợp

- Đọc DB của TV2; thống nhất API với cả nhóm.

Cách xếp hạng mã theo tin tức. Với mỗi mã, trong cửa sổ 7 / 30 / 90 ngày, chỉ tính cặp công ty chủ thể đã chấm nhãn: `rank_score = (tích cực − tiêu cực) / (tổng số bài + 5)`. Số 5 kéo điểm của mã ít bài về gần 0, để mã có 1 bài tích cực không vượt mã có 20 bài, 15 tích cực; chỉ xếp hạng mã có ít nhất 5 bài. Web luôn hiện dòng: *"Xếp hạng dựa trên nhãn tin tức do mô hình tự động chấm, chỉ để tham khảo, không phải khuyến nghị đầu tư."*

4. Schema dữ liệu chung

Đây là "hợp đồng" giữa các phần: ai cũng đọc/ghi đúng tên cột này thì làm song song được mà không phải chờ nhau.

Bảng	Cột chính	Ai ghi / ai đọc
`raw_articles`	link, domain, category, title, description, keywords, author, publication_date, content, crawled_at	TV1 ghi → TV2 đọc
`articles`	article_id (sinh từ link), link (duy nhất), domain (= nguồn tin), category, title, description, content, publication_date, article_type, is_equity, **dup_group_id**	TV2 ghi → TV3, TV4, TV5 đọc
`companies`	symbol, organ_name, old_names, brand, exchange, status	TV3 cập nhật → mọi người đọc
`article_company`	article_id, symbol, mention_count, in_title, position, is_subject, context, sentiment_label, prob_pos, prob_neu, prob_neg, model_version	TV3 ghi phần gắn công ty, TV4 ghi phần sentiment → TV5 đọc
`label_map`	source_row_id (bộ thử), article_id (mới), cách khớp	TV2 ghi → TV4 đọc
`ticker_rankings` MỚI	window_days, source, symbol, positive, neutral, negative, total, rank_score, rank_change, computed_at	Job hằng ngày (TV2) ghi → TV5 đọc

Truy vấn chính của web app: đếm `sentiment_label` trong `article_company JOIN articles` theo `symbol`, khoảng ngày và nguồn; chọn "Tất cả nguồn" thì chỉ đếm bài có `article_id = dup_group_id`.

5. Việc chung của cả nhóm: gán nhãn theo công ty

- Cần khoảng 1.500–2.000 cặp (bài, công ty) có nhãn mới, ưu tiên 534 bài nhiều công ty trong bộ nhãn cũ.
- Mỗi người gán ~300–400 cặp theo hướng dẫn của TV4 (có thể dùng Label Studio như bộ nhãn cũ).
- Khoảng 200 cặp được 2 người gán độc lập để đo độ đồng thuận; mục tiêu kappa cao hơn mức 0,63 hiện tại.
- Quy tắc: nhãn phản ánh tin này tốt / xấu / không ảnh hưởng với chính công ty đó, không phải với cả thị trường.

6. Lịch triển khai (8 tuần, bắt đầu 15/10/2026)

Tuần	Ngày	Mục tiêu	Mốc kiểm tra
1	15–21/10	Chốt schema; bắt đầu crawl lại vietstock; dựng nơi lưu chung + khung pipeline; viết hướng dẫn gán nhãn; TV3, TV5 bắt đầu trên bộ thử.	Crawl vietstock đang chạy; mọi người chạy được repo
2–3	22/10–04/11	Crawler 2 trang mới và crawl lại lịch sử; cả nhóm gán nhãn theo công ty; TV3 đo bộ gắn công ty; dựng DB.	Dữ liệu vietstock mới đã vào DB
4–5	**05–18/11**	**Crawl xong 3 trang; làm sạch, gộp tin trùng, gắn công ty trên dữ liệu mới; ánh xạ nhãn cũ; TV4 train baseline + model theo công ty; TV5 nối API với DB thật, thêm lọc nguồn và bảng xếp hạng. *(Báo cáo tiến độ 05/11.)***	**Web hiển thị dữ liệu mới (nhãn baseline), lọc được theo nguồn**
6	19–25/11	Job hằng ngày chạy tự động trọn luồng; thay nhãn baseline bằng model mới; tính xếp hạng mã mỗi ngày.	Bài hôm nay xuất hiện trên web hôm nay; Top mã cập nhật mỗi ngày
7–8	26/11–09/12	Đánh giá, sửa lỗi, tối ưu giao diện, viết báo cáo, quay video / kịch bản demo.	Bản demo hoàn chỉnh + báo cáo

Thế nào là "xong" (MVP)

- Gõ một mã (VD HPG), chọn khoảng ngày và nguồn tin → thấy số bài tích cực / tiêu cực / trung lập, biểu đồ theo thời gian và danh sách bài có link.
- Trang chủ có bảng xếp hạng mã theo tin tức (7 / 30 / 90 ngày), kèm dòng miễn trừ.
- Dữ liệu crawl mới từ 3 trang tin, phủ 2010 → hiện tại, có nội dung bài, tin trùng giữa các báo được gộp, tự cập nhật mỗi ngày.
- Có số liệu đánh giá: độ chính xác gắn công ty, macro-F1 của model theo công ty so với baseline cấp bài.